

Segmentation des utilisateurs des réseaux sociaux par apprentissage non supervisé

Es-sabbar Ismail

Étudiant en Intelligence Artificielle et Applications

Faculté Polydisciplinaire Ouarzazate

Université Ibn Zohr

Ouarzazate, Morocco

i.es-sabbar@gmail.com

Abstract—L’augmentation massive de l’utilisation des réseaux sociaux a conduit à la production d’une quantité importante de données numériques liées aux comportements des utilisateurs. L’analyse de ces données représente aujourd’hui un enjeu majeur dans plusieurs domaines tels que le marketing digital, les systèmes de recommandation et l’analyse comportementale. Dans ce travail, nous proposons une approche basée sur l’apprentissage non supervisé afin de segmenter les utilisateurs des réseaux sociaux selon leurs caractéristiques et leurs activités.

L’étude repose sur l’utilisation de différentes techniques de clustering, notamment K-Means, DBSCAN et Spectral Clustering, afin d’identifier des groupes d’utilisateurs présentant des comportements similaires. Le processus comprend le prétraitement des données, la normalisation des variables et l’application des modèles de clustering à l’aide de Python et de Scikit-learn.

Les résultats montrent que le Spectral Clustering offre les meilleures performances avec un score de silhouette de 0.67, tandis que DBSCAN détecte efficacement les comportements atypiques. Cette étude confirme l’intérêt des méthodes de clustering pour l’analyse des données sociales et la compréhension des profils utilisateurs.

Index Terms—Clustering, K-Means, DBSCAN, Spectral Clustering, HDBSCAN, PCA, t-SNE, Segmentation, Réseaux sociaux

I. INTRODUCTION

Les réseaux sociaux occupent aujourd’hui une place centrale dans la société numérique moderne. Des plateformes telles que Facebook, Instagram, TikTok et X génèrent quotidiennement d’énormes volumes de données issues des interactions des utilisateurs. Ces données représentent une source précieuse permettant de comprendre les comportements humains à grande échelle et d’améliorer les services numériques personnalisés.

Avec l’explosion du Big Data, l’analyse de ces données est devenue un domaine de recherche majeur en intelligence artificielle et en science des données. Elle permet non seulement d’extraire des connaissances utiles, mais aussi d’aider les entreprises à optimiser leurs stratégies marketing, à améliorer l’expérience utilisateur et à développer des systèmes de recommandation plus efficaces [1], [2].

Dans ce contexte, l’apprentissage automatique joue un rôle fondamental dans le traitement et l’exploitation des données massives et complexes. Parmi ses différentes branches, l’apprentissage non supervisé est particulièrement adapté aux situations où les données ne sont pas étiquetées, ce qui est souvent le cas des données issues des réseaux sociaux [3].

Le clustering est une technique centrale de l’apprentissage non supervisé. Il consiste à regrouper automatiquement les individus en clusters homogènes selon leurs similarités. Cette approche est

largement utilisée pour la segmentation des utilisateurs, la détection de communautés et l’analyse comportementale [4].

L’algorithme K-Means est l’une des méthodes de clustering les plus populaires en raison de sa simplicité et de sa rapidité. Cependant, il présente certaines limitations, notamment sa sensibilité à l’initialisation des centroïdes et la nécessité de définir à l’avance le nombre de clusters [5], [6].

D’autres approches telles que DBSCAN permettent de détecter des clusters de formes arbitraires et de gérer les données bruitées sans nécessiter la définition préalable du nombre de clusters [7]. Le clustering hiérarchique, quant à lui, fournit une représentation multi-niveaux des données mais devient coûteux en termes de calcul lorsque la taille des données augmente [8].

Des méthodes plus avancées comme Spectral Clustering et HDBSCAN ont été proposées afin de mieux traiter les structures complexes et non linéaires présentes dans les données réelles [9], [10]. Ces techniques sont particulièrement utilisées dans l’analyse des réseaux sociaux pour la détection de communautés et la segmentation des utilisateurs.

Ainsi, l’objectif principal de ce travail est d’appliquer et de comparer plusieurs techniques de clustering afin de segmenter les utilisateurs des réseaux sociaux selon leurs comportements, leurs interactions et leurs niveaux d’activité. Cette étude vise à analyser les performances et les limites de chaque méthode dans un contexte réel de données sociales [11].

II. ÉTAT DE L’ART

Le clustering est une technique fondamentale de l’apprentissage non supervisé utilisée pour découvrir des structures cachées dans les données sans avoir recours à des étiquettes. Cette approche est largement étudiée dans les domaines du data mining et de l’intelligence artificielle en raison de son efficacité dans l’analyse exploratoire des données [1].

L’un des algorithmes les plus connus est K-Means, proposé initialement par MacQueen et largement popularisé par Lloyd. Cet algorithme vise à partitionner les données en k groupes en minimisant la variance intra-cluster. Malgré sa simplicité et sa rapidité, il présente certaines limitations importantes, notamment la nécessité de définir à l’avance le nombre de clusters et sa sensibilité aux valeurs initiales des centroïdes [2], [3].

Afin de pallier ces limitations, des méthodes basées sur la densité ont été introduites. Parmi elles, DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est une approche très utilisée.

Elle permet de détecter des clusters de formes arbitraires tout en identifiant les points bruités. Contrairement à K-Means, DBSCAN ne nécessite pas la définition du nombre de clusters, ce qui constitue un avantage majeur dans les applications réelles [4].

Cependant, DBSCAN présente également des limites, notamment sa sensibilité aux paramètres ϵ et $MinPts$, ainsi que ses performances réduites dans les datasets à densité variable. Pour résoudre ce problème, des extensions telles que HDBSCAN ont été proposées. HDBSCAN améliore DBSCAN en construisant une hiérarchie de clusters basée sur la densité et en sélectionnant automatiquement les clusters les plus stables [5].

Par ailleurs, le clustering hiérarchique constitue une autre approche importante. Il permet de construire une structure arborescente des données, offrant une vision multi-niveaux des relations entre les observations. Toutefois, cette méthode devient coûteuse en termes de calcul lorsque la taille des données augmente [8].

Dans les cas où les données présentent une structure non linéaire, des méthodes basées sur les graphes comme Spectral Clustering ont été proposées. Cette technique transforme les données en un graphe de similarité et utilise les valeurs propres de la matrice de Laplace pour effectuer la segmentation. Elle est particulièrement efficace pour les données complexes mais reste coûteuse en calcul [9].

Avec l'augmentation massive des données issues des réseaux sociaux, ces méthodes de clustering sont devenues essentielles pour la segmentation des utilisateurs et la détection de communautés. Elles sont aujourd'hui largement utilisées dans des applications telles que les systèmes de recommandation, l'analyse comportementale et le marketing digital [12].

Ainsi, plusieurs études ont comparé ces algorithmes afin de déterminer leur efficacité selon les types de données. Les résultats montrent qu'il n'existe pas un algorithme universellement meilleur, mais que le choix dépend fortement de la structure des données et des objectifs de l'analyse [13], [14].

III. DATASET ET PRÉTRAITEMENT

A. Présentation du dataset

Dans cette étude, le dataset utilisé contient plusieurs informations comportementales relatives aux utilisateurs des réseaux sociaux. Les données représentent différentes caractéristiques permettant d'analyser les habitudes d'utilisation et le niveau d'engagement des utilisateurs sur les plateformes numériques.

Les principales variables exploitées dans ce travail sont les suivantes :

- Nombre de likes
- Nombre de commentaires
- Nombre de publications
- Temps d'utilisation quotidien
- Nombre d'abonnés
- Taux d'engagement
- Nombre de partages
- Nombre de réactions

Ces variables permettent de représenter le comportement numérique des utilisateurs et de construire des profils similaires à l'aide des techniques de clustering [15].

Le dataset contient plusieurs observations correspondant à différents utilisateurs. Les données sont principalement numériques, ce qui facilite l'application des algorithmes de segmentation et des méthodes de réduction de dimension.

B. Suppression des variables non pertinentes

Lors de l'étape de prétraitement, certaines variables ont été supprimées afin d'améliorer la qualité de l'analyse et d'éviter l'introduction de bruit dans les modèles de clustering.

En particulier, la colonne *Owner* a été supprimée du dataset, car elle représente un identifiant unique et ne constitue pas une caractéristique comportementale. L'inclusion de ce type de variable n'apporte aucune information utile pour mesurer la similarité entre les utilisateurs et peut biaiser les résultats des algorithmes de clustering basés sur les distances.

Ainsi, seules les variables descriptives et comportementales ont été conservées pour garantir une segmentation plus pertinente et cohérente des utilisateurs.




Fig. 1. Distribution des principales variables du dataset

La Figure 1 présente la distribution des principales variables du dataset. Cette visualisation permet d'identifier les différences de comportement entre les utilisateurs ainsi que la dispersion des données.

C. Analyse des valeurs manquantes

Une analyse des valeurs manquantes a été réalisée afin d'évaluer la qualité du dataset avant l'application des algorithmes de clustering [16].

Les résultats obtenus montrent que le dataset ne contient aucune valeur manquante dans l'ensemble des variables utilisées, comme illustré ci-dessous :




Fig. 2. Analyse des valeurs manquantes dans le dataset

Ces résultats indiquent que le dataset est complet et ne nécessite aucune étape d'imputation des valeurs manquantes. Cela constitue un avantage important, car cela permet d'éviter les biais liés au traitement des données absentes et garantit une meilleure fiabilité des résultats du clustering.




Fig. 3. Matrice de corrélation entre les variables

La Figure 3 présente la matrice de corrélation des variables étudiées et permet d'analyser les relations linéaires entre les différentes caractéristiques comportementales des utilisateurs. Cette représentation met en évidence les variables fortement corrélées, qu'elles soient positivement ou négativement liées, ce qui aide à comprendre les dépendances existantes dans les données.

Elle permet également d'identifier les redondances potentielles entre certaines variables, ainsi que celles qui apportent une information complémentaire. Ainsi, cette analyse joue un rôle important dans la phase de prétraitement des données, notamment pour la sélection des variables pertinentes dans un modèle de segmentation ou de prédiction.

D. Nettoyage des données

Le nettoyage des données constitue une étape importante dans tout processus de data mining [1]. Les valeurs manquantes ont été traitées afin d'éviter leur impact négatif sur les performances des modèles.

Les lignes contenant des valeurs incohérentes ou fortement bruitées ont été supprimées afin d'améliorer la qualité des données utilisées durant l'apprentissage.

Les valeurs aberrantes ont également été analysées à l'aide de boxplots et de méthodes statistiques afin de limiter leur influence sur les résultats du clustering [17].




Fig. 4. Détection des valeurs aberrantes avec les boxplots

La Figure 4 montre la présence de certaines valeurs extrêmes dans plusieurs variables du dataset, ce qui indique l'existence d'outliers susceptibles d'influencer l'analyse statistique et les performances des modèles. Ces valeurs aberrantes peuvent être dues à des erreurs de saisie, des comportements atypiques ou des cas rares dans les données.

L'identification de ces points extrêmes est une étape importante du prétraitement, car elle permet de décider s'il faut les supprimer, les corriger ou les conserver selon leur pertinence. Une bonne gestion de ces valeurs contribue à améliorer la robustesse et la fiabilité des résultats obtenus lors de l'analyse ou de la modélisation.

E. Normalisation des données

Les variables du dataset possèdent des échelles différentes. Par exemple, le nombre d'abonnés peut atteindre plusieurs

milliers alors que le taux d'engagement reste limité à des valeurs plus faibles.

Afin d'éviter qu'une variable domine les autres durant le clustering, une normalisation des données a été appliquée à l'aide de la méthode StandardScaler [6].

La normalisation permet d'obtenir des variables centrées autour de zéro avec une variance unitaire :

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

où :

- x représente la valeur originale,
- μ représente la moyenne,
- σ représente l'écart-type.

F. Réduction de dimension

Afin de faciliter la visualisation des données et de réduire la complexité du dataset, une réduction de dimension a été réalisée à l'aide de l'algorithme PCA (Principal Component Analysis) [18].

PCA permet de projeter les données dans un espace de dimension réduite tout en conservant le maximum d'information possible.




Fig. 5. Variance expliquée par les composantes principales (PCA)

La Figure 5 présente la variance expliquée par les composantes principales obtenues à partir de l'Analyse en Composantes Principales (PCA). On observe que la première composante principale capture une part importante de l'information contenue dans le dataset, ce qui indique qu'elle représente une forte variabilité des données.

Les composantes suivantes contribuent progressivement avec une importance décroissante, ce qui montre que l'information est concentrée principalement dans les premières dimensions. La courbe de variance cumulée confirme cette observation, puisqu'un petit nombre de composantes suffit pour expliquer une grande partie de la variance totale.

Ainsi, la réduction de dimension permet de simplifier la structure des données tout en conservant l'essentiel de l'information. Cette étape est particulièrement utile avant l'application des algorithmes de clustering, car elle améliore

la visualisation des données et peut également optimiser les performances des modèles.




Fig. 6. Projection des utilisateurs avec PCA

La Figure 6 montre la projection des utilisateurs dans un espace bidimensionnel obtenu par analyse en composantes principales (PCA). On observe une structure en colonnes verticales distinctes, ce qui traduit un problème de prétraitement des données, notamment l'absence de normalisation des variables avant la réduction dimensionnelle. Ce résultat suggère que certaines features catégorielles ont été encodées numériquement sans standardisation préalable, ce qui biaise la projection et masque la structure réelle des données.

IV. MÉTHODOLOGIE

Dans ce travail, nous appliquons des techniques d'apprentissage non supervisé afin de segmenter les utilisateurs des réseaux sociaux selon leurs comportements et interactions. L'objectif principal est d'identifier des groupes homogènes d'utilisateurs partageant des caractéristiques similaires. Avant l'application des algorithmes de clustering, les données ont été prétraitées à travers des étapes de nettoyage et de normalisation afin d'assurer la comparabilité des variables et d'améliorer la qualité des résultats [3], [4].

Une réduction de dimension a ensuite été effectuée à l'aide de l'Analyse en Composantes Principales (PCA) [18]. Cette méthode permet de transformer les variables initiales en un nouvel espace de représentation de dimension réduite, tout en conservant l'essentiel de l'information contenue dans les données. Mathématiquement, la centration des données est donnée par :

$$X_{centered} = X - \mu$$

où μ représente le vecteur des moyennes des variables. La projection des données dans le nouvel espace est ensuite définie par :

$$Z = XW$$

où W correspond à la matrice des vecteurs propres associés aux plus grandes valeurs propres.

Pour la segmentation des utilisateurs, trois algorithmes de clustering ont été utilisés. Le premier est l'algorithme K-Means [2], qui vise à partitionner les données en k groupes en minimisant la variance intra-cluster. La fonction objectif est définie par :

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

Le deuxième algorithme est DBSCAN [7], une méthode basée sur la densité qui permet d'identifier des clusters de formes arbitraires ainsi que de détecter les valeurs aberrantes. Un point est considéré comme voisin d'un autre point si :

$$N_\varepsilon(x) = \{y \mid d(x, y) < \varepsilon\}$$

et un point est qualifié de noyau si :

$$|N_\varepsilon(x)| \geq MinPts$$

Enfin, le Spectral Clustering repose sur la théorie des graphes et l'utilisation de la matrice laplacienne définie par [9] :

$$L = D - A$$

où A est la matrice de similarité et D la matrice des degrés.

Ainsi, ces trois approches complémentaires permettent une segmentation robuste des utilisateurs. La projection via PCA est utilisée pour visualiser les résultats dans un espace bidimensionnel afin de faciliter l'interprétation des clusters obtenus [1], [6].

V. RÉSULTATS

A. Détermination du nombre optimal de clusters





Fig. 7. Méthode du coude (Elbow Method)

La Figure 7 illustre la méthode du coude utilisée pour déterminer le nombre optimal de clusters k dans l'algorithme K-Means [19]. On observe que l'inertie diminue fortement lorsque k passe de 2 à 4, puis la diminution devient plus lente à partir de $k \approx 4$ ou $k = 5$. Cela indique que le point de coude se situe autour de $k = 4$, ce qui représente un bon compromis entre la compacité des clusters et la complexité du modèle. Ainsi, le nombre optimal de clusters pour ce jeu de données est estimé à $k = 4$.



Meilleur k : 10 avec un score de 0.3881

Fig. 8. Score de silhouette pour différents k

La Figure 8 présente le score de silhouette calculé pour différentes valeurs de k , afin de déterminer le nombre optimal de clusters [20]. Le score de silhouette mesure la cohésion intra-cluster et la séparation inter-cluster, avec des valeurs comprises entre -1 et 1 , où une valeur élevée indique une meilleure segmentation. On observe que le score le plus élevé est atteint pour $k = 10$ avec une valeur de 0.3881 , ce qui suggère mathématiquement que cette configuration offre la meilleure séparation des clusters. Cependant, les scores restent relativement proches pour l'ensemble des valeurs testées, ce qui indique que les données ne présentent pas de structure

de clustering très marquée. Dans ce contexte, le choix du nombre de clusters optimal doit être guidé à la fois par ce critère quantitatif et par une interprétation métier des groupes obtenus.

B. Résultats des algorithmes de clustering




Fig. 9. Clusters obtenus avec K-Means

La Figure 9 présente la projection des utilisateurs dans l'espace bidimensionnel issu de la PCA, avec une colorisation selon les clusters obtenus par K-Means. On distingue trois groupes d'utilisateurs clairement séparés le long de la première composante principale. Le cluster violet regroupe les utilisateurs situés à gauche, le cluster jaune et le cluster turquoise se partagent les colonnes centrales et droites. Toutefois, la structure en colonnes verticales confirme le problème de prétraitement évoqué précédemment, où la séparation des clusters reflète davantage la distribution des variables encodées que la similarité comportementale réelle des utilisateurs.




Fig. 10. Clusters obtenus avec DBSCAN

La Figure 10 présente les clusters obtenus par l'algorithme DBSCAN projetés dans l'espace bidimensionnel de la PCA. On distingue deux catégories de points : les points jaunes représentant les utilisateurs assignés au cluster principal, et les points violets correspondant aux points considérés comme du bruit ou des outliers par l'algorithme [7]. On remarque que les points violets sont distribués de manière quasi uniforme à travers toutes les colonnes, ce qui indique que DBSCAN éprouve des difficultés à identifier une structure de densité cohérente dans ces données. Ce comportement est directement lié au problème de prétraitement évoqué précédemment, où la structure en colonnes verticales biaise la notion de densité locale exploitée par DBSCAN. Ainsi, l'algorithme interprète une grande partie des utilisateurs comme des points aberrants, ce qui limite la pertinence de la segmentation obtenue dans ce contexte.




Fig. 11. Résultat Spectral Clustering

La Figure 11 présente les résultats du Spectral Clustering projetés dans l'espace bidimensionnel de la PCA [9]. On observe que l'algorithme identifie quatre clusters distincts, représentés par une palette de couleurs allant du violet foncé au jaune. Les clusters 0 et 1 dominent la partie gauche et centrale de la projection et regroupent la majorité des utilisateurs, tandis que les clusters 2 et 3 se concentrent principalement dans la colonne de droite, correspondant aux valeurs les plus élevées de la première composante principale. Cette localisation suggère que le Spectral Clustering parvient à capturer une structure de segmentation plus fine que K-Means, en distinguant des sous-groupes d'utilisateurs aux comportements spécifiques dans les zones de forte densité. Toutefois, la structure en colonnes verticales héritée du problème de prétraitement reste visible, ce qui limite partiellement l'interprétabilité des frontières entre les clusters obtenus.

VI. VISUALISATIONS AVANCÉES

Afin d'analyser et d'interpréter les résultats obtenus à partir des différentes méthodes de clustering, plusieurs techniques de visualisation avancées ont été utilisées. Ces visualisations jouent un rôle essentiel dans la compréhension de la structure des données et la qualité des segments formés [21].

Elles permettent notamment de représenter les utilisateurs dans un espace réduit grâce à la PCA [18], d'identifier le nombre optimal de clusters à l'aide de la méthode du coude [19], et d'évaluer la qualité des regroupements via le score de silhouette [20]. Ces outils facilitent la comparaison entre les différentes approches de clustering et offrent une meilleure interprétation des résultats obtenus dans le cadre de la segmentation des utilisateurs des réseaux sociaux [6].




Fig. 12. Projection t-SNE des données

La Figure 12 présente la projection t-SNE des utilisateurs colorisés selon leurs clusters K-Means [22]. Contrairement à la PCA, le t-SNE révèle une structure plus riche et non linéaire des données, avec la présence de plusieurs sous-groupes distincts et bien séparés dans l'espace de projection. On observe que les clusters 0 et 1 dominent la distribution et forment de nombreux îlots denses, tandis que les clusters 2 et 3 apparaissent de manière plus localisée et isolée. Cette visualisation confirme l'existence de groupes d'utilisateurs aux comportements homogènes, tout en mettant en évidence la complexité de la structure interne des données, que la PCA seule ne permettait pas de capturer.




Fig. 13. Résultat HDBSCAN avec bruit détecté

La Figure 13 présente les résultats de l'algorithme HDBSCAN projetés dans l'espace bidimensionnel de la PCA [5]. Contrairement aux autres algorithmes testés, HDBSCAN identifie un nombre élevé de clusters allant de 0 à 14, ce qui témoigne de sa capacité à détecter des structures de densité variable et des sous-groupes fins au sein des données. On observe que les clusters sont distribués de manière progressive à travers les colonnes de la projection, avec une transition graduelle des couleurs allant du jaune au violet, reflétant la hiérarchie des groupes construite par l'algorithme. La colonne gauche regroupe principalement les clusters aux indices élevés, tandis que les colonnes centrales et droites concentrent les clusters aux indices plus faibles. Par ailleurs, quelques points isolés de couleur violet foncé, correspondant au cluster -1, représentent les points considérés comme du bruit par l'algorithme. Ces résultats confirment que HDBSCAN offre une granularité de segmentation plus fine que les autres méthodes, bien que l'interprétation d'un nombre aussi élevé de clusters puisse complexifier l'analyse comportementale des utilisateurs.




Fig. 14. Comparaison finale des algorithmes de clustering

La Figure 14 présente la comparaison finale des scores de silhouette obtenus par les quatre algorithmes de clustering appliqués dans cette étude [20]. Les résultats montrent que le Spectral Clustering obtient le score le plus élevé avec une valeur de 0.67, ce qui indique une meilleure cohésion intra-cluster et une séparation inter-cluster plus nette par rapport aux autres méthodes. K-Means arrive en deuxième position avec un score de 0.61, confirmant son efficacité pour des structures de données relativement simples. Le clustering agglomératif obtient un score de 0.59, légèrement inférieur à K-Means, tandis que DBSCAN enregistre le score le plus faible avec 0.48, ce qui s'explique par la difficulté de cet algorithme à identifier des clusters de densité uniforme dans les données étudiées. Ces résultats confirment que le Spectral Clustering constitue l'approche la plus adaptée pour la segmentation des utilisateurs dans ce contexte.

VII. DISCUSSION

Les résultats obtenus permettent de comparer les performances des différents algorithmes de clustering appliqués dans cette étude [13]. Le Spectral Clustering s'est révélé le plus performant avec un score de silhouette de 0.67, confirmant sa capacité à capturer des structures complexes et non linéaires [9]. K-Means arrive en deuxième position avec 0.61, offrant une segmentation claire et interprétable malgré sa sensibilité aux valeurs aberrantes [2]. Le clustering agglomératif obtient un score de 0.59, tandis que DBSCAN enregistre le score le plus faible avec 0.48, en raison de la structure non uniforme des données [7].

HDBSCAN a permis d'identifier une segmentation plus fine avec 15 clusters distincts, reflétant la complexité réelle des profils utilisateurs [5]. La visualisation par t-SNE a confirmé l'existence de groupes homogènes bien séparés, révélant une structure interne que la PCA seule ne permettait pas de capturer [22]. Ces résultats montrent qu'il n'existe pas un algorithme universellement optimal, mais que le choix dépend de la nature des données et des objectifs de l'analyse [14].

VIII. CONCLUSION

Ce travail a présenté une étude comparative des techniques de clustering appliquées à la segmentation des utilisateurs des réseaux sociaux [1]. Nous avons appliqué et comparé quatre algorithmes principaux, à savoir K-Means, DBSCAN, Spectral Clustering et le clustering agglomératif, complétés par HDBSCAN pour une analyse plus fine des structures de densité variable [5], [9].

Les résultats obtenus montrent que le Spectral Clustering constitue l'approche la plus adaptée à ce type de données, avec un score de silhouette de 0.67, grâce à sa capacité à capturer des structures non linéaires complexes [9]. K-Means reste une méthode efficace et interprétable pour une segmentation rapide [2], tandis que DBSCAN et HDBSCAN apportent une valeur ajoutée dans la détection des comportements atypiques et des outliers [7].

La réduction de dimension par PCA et la visualisation par t-SNE ont joué un rôle essentiel dans l'interprétation des résultats, en révélant la structure interne des données et en facilitant la compréhension des groupes d'utilisateurs identifiés [18], [22].

En perspective, des améliorations peuvent être envisagées, notamment un meilleur prétraitement des variables catégorielles, l'intégration de données temporelles pour une segmentation dynamique des comportements [25], ainsi que l'application de ces techniques à des datasets plus larges issus de plateformes réelles telles que Twitter ou Instagram [12].

REFERENCES

- [1] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Morgan Kaufmann, 2011.
- [2] J. B. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proc. 5th Berkeley Symp. Mathematical Statistics and Probability*, 1967, pp. 281–297.
- [3] S. P. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [4] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proc. 2nd Int. Conf. Knowledge Discovery and Data Mining (KDD)*, 1996, pp. 226–231.
- [5] L. McInnes, J. Healy, and S. Astels, "HDBSCAN: Hierarchical density based clustering," *Journal of Open Source Software*, vol. 2, no. 11, p. 205, 2017.
- [6] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [7] M. Ankerst, M. M. Breunig, H.-P. Kriegel, and J. Sander, "OPTICS: Ordering points to identify the clustering structure," in *Proc. ACM SIGMOD Int. Conf. Management of Data*, 1999, pp. 49–60.
- [8] F. Murtagh and P. Contreras, "Algorithms for hierarchical clustering: An overview," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 2, no. 1, pp. 86–97, 2012.
- [9] U. von Luxburg, "A tutorial on spectral clustering," *Statistics and Computing*, vol. 17, no. 4, pp. 395–416, 2007.
- [10] A. Y. Ng, M. I. Jordan, and Y. Weiss, "On spectral clustering: Analysis and an algorithm," in *Advances in Neural Information Processing Systems*, 2002, pp. 849–856.
- [11] M. Steinbach, G. Karypis, and V. Kumar, "A comparison of document clustering techniques," in *Proc. KDD Workshop on Text Mining*, 2000.
- [12] S. Fortunato, "Community detection in graphs," *Physics Reports*, vol. 486, no. 3–5, pp. 75–174, 2010.
- [13] P. Berkhin, "A survey of clustering data mining techniques," in *Grouping Multidimensional Data*. Springer, 2006, pp. 25–71.
- [14] R. Xu and D. Wunsch, "Survey of clustering algorithms," *IEEE Transactions on Neural Networks*, vol. 16, no. 3, pp. 645–678, 2005.

- [15] A. K. Jain, "Data clustering: 50 years beyond K-means," *Pattern Recognition Letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [16] C. C. Aggarwal, *Data Mining: The Textbook*. Springer, 2015.
- [17] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.
- [18] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. Springer, 2002.
- [19] D. Arthur and S. Vassilvitskii, "K-means++: The advantages of careful seeding," in *Proc. 18th Annual ACM-SIAM Symp. Discrete Algorithms*, 2007, pp. 1027–1035.
- [20] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987.
- [21] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning*. Springer, 2013.
- [22] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.
- [23] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [24] W. Zhao, J. Ma, and Q. He, "Parallel K-Means clustering based on MapReduce," in *Proc. IEEE Int. Conf. Cloud Computing*, 2009, pp. 674–679.
- [25] A. Bhatnagar and V. Ghose, "A latent class segmentation analysis of e-shoppers," *Journal of Business Research*, vol. 57, no. 12, pp. 1357–1392, 2004.